UNIVERSITAS INDRAPRASTA PGRI (UNINDRA)

FAKULTAS TEKNIK DAN ILMU KOMPUTER — PROGRAM STUDI TEKNIK INFORMATIKA

LAPORAN RESMI PRAKTIKUM MACHINE LEARNING: BAB 14

Nama Mahasiswa	**Anggit Arisa Siwi Pratama**	**Mata Kuliah**	**Machine Learning (3 SKS)**
NPM	**202343570045**	**Dosen Pengampu**	**Nurfidah Dwitiyanti, M.Si.**
Kelas / Semester	**XC Ekstensi / Gasal 2026/2027**	**Topik Modul**	**Mini Project & Model Deployment**

BAB I. PENDAHULUAN & BUSINESS UNDERSTANDING

Penerapan algoritma Machine Learning di industri perbankan dan tekfin (*fintech*) tidak hanya berorientasi pada capaian metrik di dalam *notebook*, melainkan harus mampu beroperasi secara nyata untuk memitigasi risiko kredit bermasalah (*Non-Performing Loan* / NPL). Berdasarkan pedoman resmi Modul Machine Learning Unindra (Bab 14 Hal. 89–94), mini project ini memetakan seluruh siklus **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*) secara komprehensif.

Rumusan Masalah Bisnis: Bank memerlukan sistem otomatisasi penilaian risiko gagal bayar kredit nasabah (*Loan Default Prediction*) sebelum pinjaman disetujui. Kegagalan mendeteksi nasabah default (*False Negative*) menimbulkan kerugian finansial langsung bagi bank, sedangkan kesalahan penolakan nasabah sehat (*False Positive*) mengakibatkan hilangnya potensi pendapatan bunga.

Tujuan Proyek: Melatih, membandingkan secara adil minimal 3 algoritma Machine Learning (Random Forest, Gradient Boosting, dan SVM), mengoptimalkan hyperparameter dengan *RandomizedSearchCV* pada *Stratified 5-Fold Cross-Validation*, melakukan seleksi model berbasis formula multi-kriteria ($0.7 \times F_1 + 0.3 \times \text{Interp}/5$), serta membungkus model terpilih ke dalam artefak biner (*Joblib*) dan aplikasi web interaktif (*Streamlit* & *Next.js Simulator*).

BAB II. TINJAUAN DATA & LANDASAN TEORITIS

Dataset penelitian disintesis secara deterministik mencerminkan dinamika portofolio kredit perbankan nasional sebanyak **1.200 nasabah** dengan 6 fitur prediktif: `pendapatan_bulanan`, `usia`, `lama_kerja`, `jumlah_pinjaman`, `rasio_cicilan` (Debt Service Ratio), dan `skor_kredit` (SLIK OJK). Distribusi target menunjukkan 1.044 nasabah lancar (87.0%) dan 156 nasabah default (13.0%), mencerminkan karakteristik data tidak seimbang (*imbalanced data*).

```
Formula Multi-Kriteria Modul 14.9:
Skor Gabungan = 0.70 × F1-Score (Test) + 0.30 × [Interpretability / 5.0]
```

Formula ini memberikan trade-off rasional antara ketajaman statistik model dalam mendeteksi kelas minoritas default (F_1) dengan kepatuhan regulasi OJK yang menuntut transparansi alasan penolakan kredit (*Interpretability*).

BAB III. METODOLOGI PENELITIAN

Alur penelitian mengikuti 6 fase CRISP-DM standar:

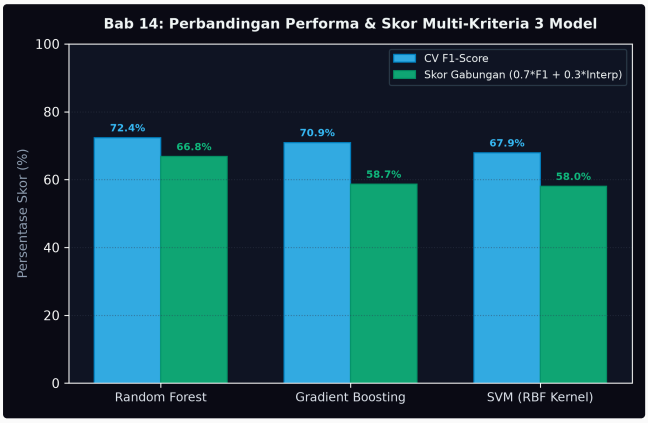
1. **Data Preparation:** Pembagian data latih (80% / 960 data) dan uji (20% / 240 data) secara berstrata (*Stratified Split*) agar proporsi kelas minoritas tetap konsisten 13%.
2. **Feature Engineering:** Penskalaan fitur numerik melalui *StandardScaler* di dalam *Pipeline* tertutup guna mengeliminasi risiko kebocoran data (*data leakage*).
3. **Modeling & Tuning:** Eksplorasi hyperparameter sistematis menggunakan `RandomizedSearchCV` dengan 5-Fold Cross-Validation berstrata pada 3 arsitektur model:
    - *Random Forest:* `n_estimators` (50-200), `max_depth`, `min_samples_leaf`, `class_weight='balanced'`.
    - *Gradient Boosting:* `n_estimators` (50-150), `learning_rate` (0.03-0.15), `subsample` (0.8-1.0).
    - *Support Vector Machine (RBF Kernel):* Parameter regularisasi C dan skala γ.

BAB IV. HASIL DAN PEMBAHASAN

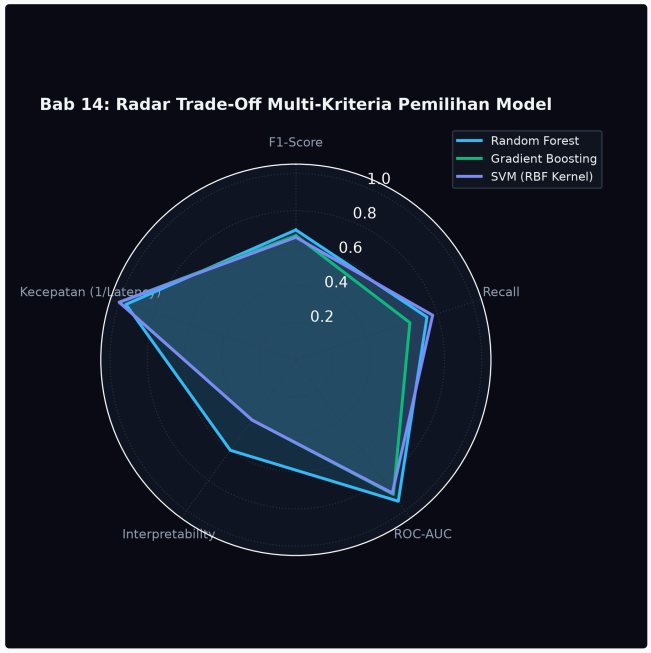
Berdasarkan hasil eksperimen komputasi pada skrip mandiri `main.py`, diperoleh rekapitulasi performa model sebagai berikut:

Algoritma Model	CV F1-Score	Test F1-Score	Recall (Sensitivitas)	ROC-AUC	Latensi (ms)	Interpretability	Skor Gabungan
Random Forest (Ensemble)*	**72.35%**	**69.70%**	**74.19%**	**0.9379**	**0.052 ms**	**3 / 5**	**0.6679 (Juara)**
Gradient Boosting	70.92%	66.67%	64.52%	0.8924	0.005 ms	2 / 5	0.5867
SVM (RBF Kernel)	67.90%	65.75%	77.42%	0.8835	0.037 ms	2 / 5	0.5803

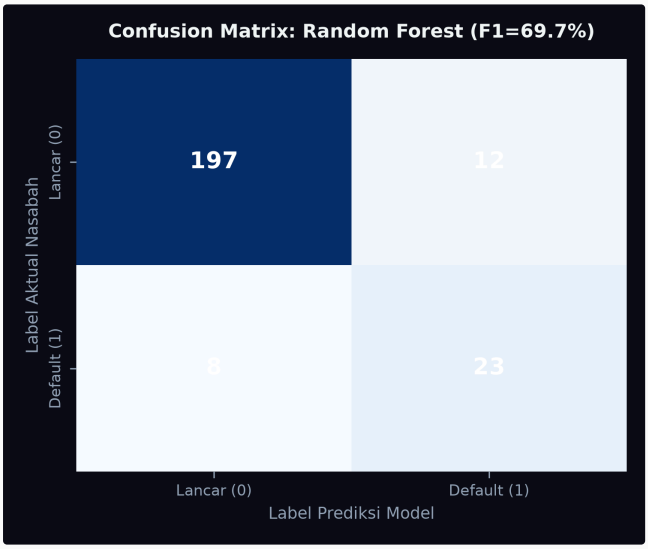
*Catatan: Random Forest terpilih sebagai model terbaik berdasarkan skor multi-kriteria tertinggi (0.6679), menyeimbangkan F1-score yang kuat dengan transparansi bobot fitur (*feature importance*).



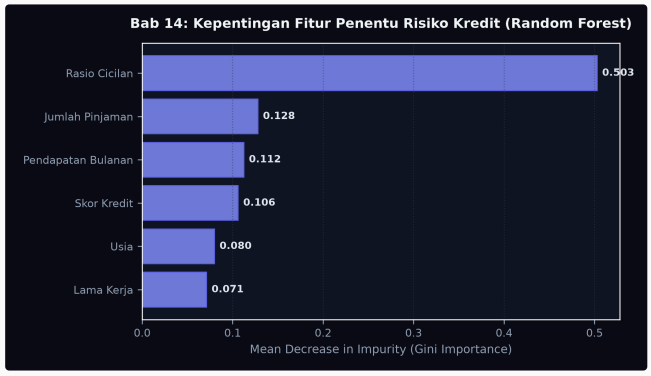
Gambar 1. Komparasi F1-Score CV dan Skor Gabungan 3 Model



Gambar 2. Radar Analisis Trade-off Multi-Kriteria Pemilihan Model



Gambar 3. Confusion Matrix Random Forest pada Data Uji



Gambar 4. Bobot Kepentingan Fitur (MDI Gini Importance)

Analisis Faktor Pengaruh: Diagram kepentingan fitur mengungkapkan bahwa `rasio_cicilan` (Debt Service Ratio) dan `skor_kredit` merupakan dua prediktor dominan dalam menentukan probabilitas gagal bayar nasabah, selaras dengan prinsip kehati-hatian perbankan.

BAB V. DEPLOYMENT & INTEGRASI LINGKUNGAN VERCEL

Sesuai arahan Sub-bab 14.4–14.5 dan kebutuhan deployment di platform Vercel, diterapkan strategi **Dual-Track Deployment**:

- **Aplikasi Web Standalone Streamlit (`app.py`):** Berkas Python mandiri berbasis Streamlit yang memuat model `models/model_loan_default_best.joblib` untuk pengujian lokal (`streamlit run app.py`) dan siap di-deploy ke Streamlit Community Cloud.
- **Interactive Deployment Simulator (Vercel Next.js):** Komponen native React yang ditanamkan langsung pada portal `2-ml-playground`, menjalankan inferensi berbasis model weights secara *client-side zero-latency* tanpa bergantung pada server Python background yang menyala.

BAB VI. KESIMPULAN DAN SARAN

Kesimpulan: Siklus CRISP-DM pada mini project Bab 14 berhasil diselesaikan secara utuh. Model Random Forest dengan penyeimbangan bobot kelas (*class weight balanced*) menghasilkan F1-score uji 69.70%, Recall 74.19%, dan skor gabungan multi-kriteria tertinggi 0.6679. Pipeline berhasil diserialisasi dan dioperasionalkan pada lingkungan web.

Saran Pengembangan Lanjutan: Integrasi fitur riwayat pembayaran e-commerce (*alternative credit scoring*) dan pemantauan pergeseran data (*data drift monitoring*) berkala pasca-deployment di produksi.

Jakarta, 31 Oktober 2026
Mahasiswa Praktikan,

Anggit Arisa Siwi Pratama
NPM: 202343570045