**Latihan Kisi-kisi UTS**

**1. Studi kasus.** KirimCepat, perusahaan jasa pengiriman paket, ingin memprediksi paket yang akan terlambat sampai agar pelanggan dapat diberi tahu lebih awal. Tersedia 10.000 data pengiriman berlabel: 8.800 tepat waktu dan 1.200 terlambat. Kelas positif adalah terlambat. Bulatkan hasil akhir ke 3 desimal.

a. Tentukan kategori ML, jenis tugas, target, dan metrik utama kasus ini. Hitung akurasi model yang menebak semua paket "tepat waktu" dan jelaskan mengapa akurasi tidak layak menjadi metrik utama.

b. Sebutkan fase CRISP-DM yang harus dikunjungi kembali dan tindakan perbaikannya untuk temuan: (1) Tim operasional belum menentukan apakah "terlambat" berarti melewati estimasi 1 hari atau 3 hari. (2) Kolom tanggal_diterima ikut dipakai sebagai fitur input.

c. Data dibagi secara stratified dengan proporsi train : validation : test = 70 : 10 : 20. Hitung jumlah paket tepat waktu dan terlambat pada tiap subset, dan tuliskan fungsi tiap subset.

d. F1 train dan F1 validation tiga model: P = 0,52 dan 0,51; Q = 0,80 dan 0,77; R = 0,97 dan 0,65. Hitung gap tiap model, diagnosis kondisinya, beri satu tindakan perbaikan untuk P dan R, lalu pilih model yang dilanjutkan.

2. a. Sampel berat paket (kg): 1, 2, 2, 3, 3, 4, 5, 18. Hitung Q1, Q3, IQR, dan batas outlier; tentukan kandidat outlier dan apakah nilai itu sebaiknya dihapus.

b. Jarak pengiriman lima paket (km): 5, 8, 10, 12, 65, dan satu nilai kosong. Hitung nilai imputasi dengan mean dan dengan median, lalu pilih yang lebih tepat. Bila pada data train $\mu = 15$ dan $\sigma = 12$, hitung Z-score paket berjarak 55 km dan tentukan apakah ia kandidat outlier ($|z| > 3$).

c. Dengan data train dari Soal 1c, hitung class weight $w_k = N / (K \times n_k)$ untuk kelas tepat waktu dan terlambat, lalu jelaskan arti perbandingannya.

d. SMOTE: dari $x_i = (2, 7)$ dan tetangganya $x_j = (8, 4)$ dengan $\lambda = 1/3$, hitung $x_{baru} = x_i + \lambda(x_j - x_i)$. Mengapa SMOTE hanya diterapkan pada data train?

3. a. Hitung frekuensi harapan dan $\chi^2 = \Sigma (O - E)^2 / E$ dari tabel berikut. Dengan nilai kritis 3,84 (df = 1, $\alpha = 0,05$), simpulkan apakah fitur "layanan ekonomi" layak dipertahankan.

| Layanan ekonomi | Terlambat | Tepat waktu | Total |
|---|---|---|---|
| Ya | 36 | 64 | 100 |
| Tidak | 14 | 86 | 100 |

b. Kolom dataset: berat_kg (numerik, ada nilai kosong), jarak_km (numerik, distribusi miring), kota_tujuan (nominal), jenis_layanan (nominal), tingkat_prioritas (rendah < sedang < tinggi), waktu_pemesanan (timestamp), tanggal_diterima (diisi saat paket sampai). Rancang perlakuan ColumnTransformer untuk kolom numerik, nominal, dan ordinal; usulkan dua fitur baru; dan tentukan kolom yang harus dibuang beserta alasannya.

4. a. Sebuah node berisi 6 terlambat dan 14 tepat waktu.

   Kandidat split:

   X (cuaca buruk di rute?): Ya: 4 terlambat, 1 tepat; Tidak: 2 terlambat, 13 tepat.

   Y (layanan ekonomi?) : Ya: 4 terlambat, 6 tepat; Tidak: 2 terlambat, 8 tepat.

   Hitung Gini induk dan Gini tertimbang tiap kandidat, lalu tentukan split yang dipilih CART.

   b. Ulangi butir a dengan Entropy dan Information Gain (log2 x = ln x / ln 2). Apakah ID3 memilih split yang sama?

   c. Tiga pohon hasil pruning: T1: R = 0,11, 22 leaf; T2: R = 0,15, 8 leaf; T3: R = 0,23, 3 leaf. Dengan $C\alpha(T) = R(T) + \alpha \times$ jumlah leaf, tentukan pohon terpilih untuk $\alpha = 0{,}004$ dan $\alpha = 0{,}025$, lalu jelaskan pengaruh kenaikan α terhadap bias dan variance.

   d. Hasil validation curve ditunjukkan di bawah. Tentukan max_depth terbaik dan jelaskan kondisi model pada depth 1 dan depth 10.

| **max_depth** | **1** | **2** | **3** | **5** | **7** | **10** |
|---|---|---|---|---|---|---|
| Akurasi train | 0,69 | 0,77 | 0,84 | 0,90 | 0,95 | 0,99 |
| Akurasi validation | 0,68 | 0,75 | 0,81 | 0,79 | 0,76 | 0,70 |

5. a. Data latih berikut sudah diskalakan dan paket baru q = (3, 5). Hitung jarak Euclidean q ke tiap data, lalu tentukan prediksi KNN k = 3 dengan voting mayoritas dan dengan weighted KNN (w = 1/d). Apakah keputusannya berubah?

| **Data** | **D1** | **D2** | **D3** | **D4** | **D5** |
|---|---|---|---|---|---|
| Skor jarak | 4 | 6 | 0 | 9 | 3 |
| Skor beban gudang | 6 | 9 | 1 | 13 | 17 |
| Kelas | Terlambat | Tepat waktu | Tepat waktu | Terlambat | Tepat waktu |

   b. Ulangi butir a dengan jarak Manhattan. Apakah tiga tetangga terdekat dan prediksinya berubah?

   c. Hasil 5-fold cross-validation pada data train ditunjukkan di bawah. Tentukan k terbaik, jelaskan kondisi model pada k = 1 dan k = 21, dan jelaskan mengapa k tidak dipilih dari akurasi train.

| **k** | **1** | **3** | **5** | **7** | **9** | **15** | **21** |
|---|---|---|---|---|---|---|---|
| Akurasi train | 1,00 | 0,93 | 0,90 | 0,88 | 0,86 | 0,83 | 0,80 |
| Rata-rata akurasi CV | 0,77 | 0,82 | 0,85 | 0,86 | 0,84 | 0,81 | 0,78 |

   d. Mengapa fitur harus diskalakan sebelum menghitung jarak KNN? Beri contoh dari kasus ini.